


Rapport de projet de fin de semestre



Encadré par : Prof. Fahd Kalloubi

Réalisé par : Bayane TOUKI

1. Introduction

1.1 Contexte et Problématique

Le Machine Learning (ML) permet aux systèmes d'apprendre automatiquement à partir des données. Ce projet applique des algorithmes de classification supervisée au dataset Breast Cancer Wisconsin pour prédire si une tumeur est maligne ou bénigne. Un diagnostic précoce et précis est crucial pour améliorer le taux de survie des patients.

1.2 Objectifs

Implémenter et comparer 6 algorithmes de classification supervisée.

Évaluer leurs performances via des métriques appropriées (accuracy, cross-validation, F1-score).

Identifier le meilleur modèle pour ce problème de classification binaire médicale.

Analyser l'importance des features pour comprendre les caractéristiques discriminantes.

2. Prétraitement des Données

Le dataset a été divisé en 80% entraînement (455 exemples) et 20% test (114 exemples) avec stratify=y pour préserver les proportions entre classes. La normalisation (StandardScaler : moyenne=0, écart-type=1) est appliquée uniquement sur les données d'entraînement pour éviter tout data leakage.


$$z = (x - \mu) / \sigma$$

La normalisation est indispensable pour KNN et SVM (sensibles aux distances), et non nuisible pour les algorithmes basés sur les arbres.

3. Algorithmes de Classification Utilisés


3.1 Decision Tree (max_depth=5)

Partitionne récursivement l'espace des features par des tests binaires. Chaque feuille représente une classe. Le critère Gini minimise l'impureté à chaque nœud. La profondeur limitée à 5 évite le surapprentissage.




3.2 Random Forest (n_estimators=100)

Méthode ensembliste : 100 arbres de décision indépendants, entraînés sur des sous-ensembles aléatoires (bagging). La prédiction finale est le vote majoritaire, réduisant la variance par rapport à un seul arbre.




3.3 Logistic Regression (max_iter=10000)

Modélise la probabilité d'appartenance à une classe via la fonction sigmoïde sur une combinaison linéaire des features. Optimisée par minimisation de la perte log-loss. Malgré sa simplicité, très compétitive sur ce dataset.




3.4 K-Nearest Neighbors - KNN (k=5)

Algorithme non-paramétrique : classe un exemple selon la majorité parmi ses 5 voisins les plus proches (distance Euclidienne). Pas de phase d'entraînement explicite. La normalisation est indispensable.




3.5 SVM Linéaire (kernel='linear')

Cherche l'hyperplan de séparation optimal maximisant la marge entre les deux classes. Très efficace après normalisation, grâce à la séparabilité quasi-linéaire des classes dans l'espace de 30 dimensions.



3.6 AdaBoost (n_estimators=100)

Boosting séquentiel : combine 100 stumps (arbres à un nœud). À chaque itération, les exemples mal classifiés reçoivent un poids plus élevé. La prédiction finale est une combinaison pondérée de tous les classifieurs.



Pour évaluer la performance de chaque modèle, on a utilisé plusieurs métriques complémentaires, adaptées à un problème de classification binaire.

Accuracy (Précision Globale)

$$\text{Accuracy} = (\text{VP} + \text{VN}) / (\text{VP} + \text{VN} + \text{FP} + \text{FN})$$

Cross-Validation (5-fold)

Rapport de Classification

Matrice de Confusion

4. Résultats et Comparaison des Modèles

4.1 Tableau comparatif

Rang	Algorithme	Accuracy (Test)	Cross-Val 5-fold	Statut
1	Random Forest	95.61 %	95.38%	Meilleur
1	SVM Linéaire	97.37%	96.70%	Bon
2	Logistic Regression	98.25%	98.02%	Bon
3	AdaBoost	95.61%	97.36%	Correct
3	KNN (k=5)	95.61%	96.70%	Correct
4	Decision Tree	92.11%	93.19%	Correct

4.2 Analyse

La Régression Logistique atteint la meilleure performance (98.25% test, 98.02% CV), confirmant l'adéquation d'un modèle linéaire pour ce dataset bien normalisé. Le SVM Linéaire tire profit de la séparabilité dans l'espace de 30 dimensions. Le Random Forest, AdaBoost et KNN atteignent 95.61% en test. L'arbre de décision est le moins performant mais reste le seul modèle entièrement interprétable.

4.3 Importance des features (Random Forest)

Les variables les plus discriminantes sont les worst values des caractéristiques géométriques : worst radius, worst perimeter et worst area. Médicalement cohérent : les tumeurs malignes présentent des cellules de grande taille aux contours irréguliers. : worst radius, worst perimeter et worst area. Ces résultats sont médicalement cohérents : les tumeurs malignes tendent à présenter des cellules de grande taille et aux contours irréguliers.

5. Discussion

5.1 Choix du meilleur modèle

La Régression Logistique et le SVM Linéaire se distinguent comme les meilleures approches. Dans un contexte médical, le rappel sur la classe maligne est la métrique la plus critique : un Faux Négatif (cancer non détecté) est bien plus coûteux qu'un Faux Positif. Il est recommandé d'ajuster le seuil de décision pour maximiser ce rappel.

5.2 Limites et pistes d'amélioration

Dataset de taille modeste (569 exemples) ; les réseaux profonds nécessiteraient plus de données.

Hyperparamètres par défaut : une recherche GridSearchCV pourrait améliorer les performances.

Perspectives : XGBoost, Gradient Boosting, réduction dimensionnelle (PCA), ajustement du seuil.

6. Conclusion

Ce projet a permis de comparer 6 algorithmes de classification sur le dataset Breast Cancer Wisconsin selon une méthodologie rigoureuse (exploration, prétraitement, entraînement, cross-validation). Les accuracies obtenues entre 92% et 98% confirment la bonne séparabilité des classes et l'efficacité des algorithmes ML classiques pour ce problème.

La Régression Logistique et le SVM Linéaire se distinguent comme les meilleures approches. L'importance de la normalisation (KNN, SVM) et l'apport des méthodes ensemblistes ont été clairement illustrés. L'interprétabilité du Decision Tree reste un atout précieux en contexte médical.